INSTITUT TEKNOLOGI SUMATERA
Program Studi Teknik Informatika — Mahadata / Big Data (IF25-40402)

Replikasi Parsial Regresi Panel Efek Tetap pada Apache Spark: Studi Artikel Bluhm & Cutura (2022)

Tugas Eksplorasi Mandiri Apache Spark dan NoSQL

Nama : M. Fadhil Hawari
NIM / Kelas : 123140147
Repositori : https://github.com/hawaricracker/mahadata

A. Ringkasan Jurnal

Artikel. Bluhm, B., & Cutura, J. A. (2022). Econometrics at scale: Spark up big data in economics. *Journal of Data Science, 20*(3), 413–436. `https://doi.org/10.6339/22-JDS1035`. Dikirim 9 November 2021, diterima 12 Januari 2022, terbit Juli 2022. Kuartil jurnal: Q3.

Masalah. Data ekonomi dan keuangan makin besar sehingga tidak muat di memori satu komputer, sementara paket ekonometrika yang lazim dipakai tidak dirancang untuk data terdistribusi. Artikel ini menunjukkan cara memakai Spark untuk tugas ekonometrika standar.

Metode (Bagian 4.3). Penulis membuat data panel buatan sebesar sekitar 90 GB (satu miliar baris), lalu menjalankan tiga analisis regresi di Spark: (i) regresi biasa (OLS) sebagai pembanding, (ii) regresi efek tetap, yaitu regresi yang menghilangkan pengaruh ciri tiap individu yang tidak teramati, dan (iii) perhitungan galat baku (ukuran ketidakpastian estimasi) yang tetap andal walau galat tidak seragam, dengan cara membagi data ke beberapa bagian lalu menggabungkan hasilnya.

Lingkungan dan hasil utama. Eksperimen penuh dijalankan di klaster AWS. Pada contoh kecil (100.000 baris), hasil Spark sama dengan hasil paket R `plm`. Regresi biasa menghasilkan koefisien X_1 sekitar 1 padahal nilai sebenarnya 0,5, sedangkan regresi efek tetap mendekati 0,5. Spark baru berguna untuk data besar; pada data kecil Spark tidak lebih cepat.

Alasan memilih. Kode tersedia di GitHub penulis, datanya simulasi sehingga dapat dibangkitkan ulang pada ukuran yang sesuai laptop, dan artikel menyediakan pembanding yang jelas pada Tabel 2.

B. Tahapan Eksperimen

Tingkat replikasi: replikasi parsial (Bagian 4.3).

Rancangan. Tujuan: memeriksa apakah (1) bias OLS dan koreksinya oleh efek tetap, serta (2) galat baku terdistribusi, dapat direproduksi, dan bagaimana waktu eksekusinya pada data kecil.

Data. Data dibuat sendiri dengan simulasi dan meniru cara artikel membuat datanya. Ada 2.000 individu yang masing-masing diamati selama 10 periode, sehingga totalnya 20.000 baris. Setiap baris berisi satu nilai hasil dan tujuh variabel penjelas (X_1 sampai X_7). Pengaruh sebenarnya setiap variabel terhadap hasil ditetapkan 0,5. Setiap individu juga punya ciri bawaan yang tidak

teramati dan nilainya tetap sepanjang waktu. Ciri ini sengaja dibuat berhubungan dengan X_1, sehingga regresi biasa akan keliru menaksir pengaruh X_1, sedangkan regresi efek tetap dapat memperbaikinya. Angka acak dikunci dengan *seed* 13 agar hasilnya dapat diulang.

Lingkungan. Spark mode lokal, PySpark, Python 3.12

Langkah.

1. Simulasi data dengan NumPy/pandas, lalu dijadikan Spark DataFrame.
2. OLS dengan `GeneralizedLinearRegression`.
3. Transformasi *within* dengan Spark SQL, lalu regresi ulang dan koreksi galat baku: faktor $(NT - K)/(N(T - 1) - K)$ dengan $K = 8$.
4. Galat baku *panel-robust*: hitung residu, partisi RDD per `id` (1.000 partisi), hitung *bread* dan *meat* per partisi, lalu $\hat{V} = B^{-1}MB^{-1}$.
5. Validasi silang dengan paket Python `linearmodels` 7.0 pada data yang sama.

Perbedaan terhadap artikel.

- Data 20.000 baris, bukan subsampel 100.000 baris maupun 1 miliar baris. Kolom AWS pada Tabel 2 artikel tidak direplikasi karena memerlukan klaster.
- Data dibangkitkan ulang dengan *seed* sendiri, sehingga angka tidak identik dengan artikel; yang dibandingkan adalah pola dan kedekatan ke nilai sebenarnya.
- Pembanding memakai `linearmodels` (Python), bukan R `plm`.

C. Hasil dan Analisis

Tabel 1: Estimasi koefisien dan galat baku ($N = 2.000$, $T = 10$; nilai sebenarnya 0,5). *Adj.* = galat baku disesuaikan derajat bebas; *Robust* = galat baku *panel-robust*. S = Spark, L = `linearmodels`.

	OLS	FE	SE Adj.		SE Robust	
	koef.	koef.	S	L	S	L
X_1	1,0036	0,5081	0,007531	0,007531	0,007678	0,007679
X_2	0,5008	0,4994	0,007519	0,007519	0,007739	0,007740
X_3	0,4872	0,4984	0,007434	0,007434	0,007349	0,007350
X_4	0,5092	0,5038	0,007478	0,007478	0,007484	0,007485
X_5	0,4980	0,4945	0,007481	0,007481	0,007581	0,007582
X_6	0,4879	0,4962	0,007487	0,007487	0,007294	0,007295
X_7	0,4998	0,5007	0,007447	0,007447	0,007458	0,007460

Analisis.

1. *Bias OLS direplikasi.* Koefisien X_1 pada OLS adalah 1,0036, mendekati 0,9975 pada artikel. Ini sesuai teori: karena $\mathrm{Var}(X_1) = 2$ dan $\mathrm{Cov}(X_1, \alpha_i) = 1$, bias variabel yang terlewat adalah $1/2$, sehingga estimasi konvergen ke $0{,}5 + 0{,}5 = 1$. Koefisien lain tidak bias karena tidak berkorelasi dengan α_i.

Tabel 2: Waktu eksekusi satu kali jalan (detik). Nilai artikel dikonversi dari menit (kolom Spark lokal, 100.000 baris, mesin berbeda), sehingga hanya sebanding secara urutan.

Spesifikasi	Eksperimen ini (20.000 baris)	Artikel (100.000 baris)
OLS	8,2	1,0
Efek tetap (transformasi + estimasi)	10,4	5,0
Efek tetap + VCE robust	30,1	22,0

2. *Efek tetap memperbaiki bias.* Koefisien X_1 turun ke 0,5081 dan semua koefisien berada dalam sekitar 1,1 galat baku dari 0,5, sesuai variasi sampling.

3. *Galat baku terdistribusi valid.* Galat baku Spark sama dengan `linearmodels` hingga enam desimal untuk koreksi derajat bebas. Untuk versi *robust*, selisih paling besar 2×10^{-6} ($< 0{,}03\%$); penyebabnya kemungkinan perbedaan konvensi koreksi sampel kecil antar implementasi. Ini sejalan dengan artikel, yang juga memperoleh galat baku sama antara Spark dan `plm`.

4. *Skala galat baku konsisten dengan artikel.* Galat baku efek tetap artikel (100.000 baris) sekitar 0,00334, sedangkan di sini 0,00753 dengan 20.000 baris. Rasionya 2,26, dekat dengan $\sqrt{100.000/20.000} = 2{,}24$ yang diharapkan.

5. *Galat baku robust mirip yang biasa.* Sesuai harapan, karena galat u_{it} pada simulasi bersifat homoskedastik dan tidak berkorelasi serial. Pada artikel juga demikian (0,003342 vs 0,003339 untuk X_1).

6. *Waktu eksekusi.* Urutan waktu OLS < efek tetap < robust sama dengan artikel. Pada 20.000 baris waktu didominasi *overhead* Spark, bukan volume data, sehingga tidak ada keuntungan dari distribusi; hal ini juga disimpulkan artikel untuk subsampel. Waktu OLS yang relatif besar kemungkinan memuat inisialisasi *job* pertama, dan VCE robust lambat kemungkinan karena 1.000 partisi untuk hanya 2.000 individu (sekitar dua individu per partisi); keduanya dugaan yang belum diuji.

Keterbatasan. Satu kali eksekusi tanpa pengulangan (waktu tidak dirata-rata); data kecil dan tanpa klaster sehingga keunggulan Spark pada data besar tidak teruji; pembanding bukan R `plm`; waktu eksekusi tidak dapat dibandingkan langsung dengan artikel karena perangkat keras berbeda.

D. Kendala dan Refleksi

- **Data asli terlalu besar.** Data artikel (90 GB) tidak praktis dijalankan di laptop, sehingga data dibuat ulang dalam ukuran kecil dengan cara yang sama.
- **Spark terasa lambat pada data kecil.** Untuk 20.000 baris, eksekusi memakan waktu puluhan detik karena beban kerja Spark untuk mengatur proses lebih besar daripada perhitungannya sendiri.
- **Bila diulang:** eksperimen dijalankan beberapa kali dan dirata-rata, memakai data yang lebih besar untuk melihat kapan Spark mulai lebih cepat, serta dibandingkan dengan paket R `plm` seperti di artikel.

E. Tautan Kode

Repositori: https://github.com/hawaricracker/mahadata

Kode utama diadaptasi dari repositori penulis artikel (`https://github.com/benjaminbluhm/econometrics_at_scale`, folder `chapter_4.3`); bagian yang diubah dan skrip validasi `linearmodels` ditandai pada repositori.

References

[1] Bluhm, B., & Cutura, J. A. (2022). Econometrics at scale: Spark up big data in economics. *Journal of Data Science, 20*(3), 413–436. `https://doi.org/10.6339/22-JDS1035`